


RAG



Retrieval-Augmented Generation


BY:
HAROLD LAGARES



LIMITACIONES DEL PARAGDIMA PARÁMETRICO PURO

¿Por qué nace el RAG? 🔍

- Conocimiento Estático
- Alucinaciones Factuales
- Sin Trazabilidad
- Contexto Finito




RAG VS ALTERNATIVAS DE ADAPTACIÓN

<i>Enfoque</i>	<i>¿Actualizable?</i>	<i>Costo</i>	<i>Trazable</i>	<i>Conocimimientto Privado</i>
Fine-tuning	✗	Muy Alto	✗	Parcial
Prompt Engineering	✓	Bajo	✗	✗
RAG	✓	Medio	✓	✓



PIPELINE






BÚSQUEDA VECTORIAL

- Espacio Latente
- Similitud Semántica
- Contrastive Learning




$[0.12, -0.45, 0.89...]$






CHUNKING


Fixed-Size




Semantic




Hierarchical





RE-RANKING



- BI-Encoder
- Cross-Encoder
- Hibrido (Two-stage)

PUNTOS CIEGOS DEL RAG

Fallos de Retrieval



- **Multi-hop:** Falla al encadenar múltiples documentos dispersos.
- **Temporal:** No distingue versiones desactualizadas del mismo documento.

Fallos de Generación



- **Context Window:** El límite de tokens fuerza a truncar información vital.
- **Lost in the Middle:** El LLM ignora información relevante si está enterrada en el medio del prompt.

Fallos Operacionales



- **Latencia:** Múltiples saltos (Embedding -> Search -> Rerank) matan el tiempo real.
- **Diálogos:** Sin memoria nativa para conversaciones largas.

EL NACIMIENTO DEL RECALLM

